

LLMOps 기능 이해와 운영 가이드

GovBiz · React 관리자 화면에서 평가하고, 검토하고, 다음 비교 기준을 남기는 방법

무엇을 누르면 무엇이 바뀌는지,
결과 숫자는 어디까지 믿어도 되는지 설명합니다.

실행

자료와 비교 대상을 선택



해석

답변·지표·비용을 확인



검토

판단 근거와 기준을 저장

이 시스템이 해결하는 질문

“모델이나 프롬프트를 바꾼 뒤, 같은 질문에 더 나은 답을 하는가?”를 기록과 근거로 확인합니다. 실패·사용량·사람의 판단도 함께 보존합니다.

이 문서의 독자

LLMOps를 처음 사용하는 프로젝트 관리자, 평가 결과를 검토하는 팀원, 기존 검토 기록을 자신의 로컬 환경에서 확인하려는 팀원을 위한 가이드입니다.

읽는 순서

- 처음이라면: 2~7쪽에서 구조와 화면부터 이해합니다.
- 실제로 평가하려면: 8~17쪽에서 실행·검토·예산·복구 절차를 봅니다.
- 팀원과 공유하려면: 19쪽과 22쪽의 환경 이전·문제 해결을 봅니다.

문서 기준

소스 기준: skn-225 / 27ad7ee. 화면 확인: 2026-10-06 KST. 실행 ID와 수치는 그 시점의 예시입니다. 이 가이드를 만드는 동안 새 평가·검토 저장·예산 변경은 하지 않았습니다.

목차와 5분 시작 안내

궁금한 내용	페이지
시스템 구조 / 기본 용어 / 평가 방식	3 / 4 / 5
목록 화면 / 읽기만 하는 첫 실습	6 / 7
저장 응답 재평가 / 새 응답 생성	8 / 9
실행 상세 / 지표 해석	10 / 11
고정 근거 검토 / 판단 사유 작성	12 / 13
RAG 검토 / 비교 기준 관리	14 / 15
예산 / 취소·복구	16 / 17
보고서·추적 / 팀원 공유	18 / 19
정기 실행·알림 / 실제 사례	20 / 21
문제 해결 / 용어·자료 위치	22 / 23

우선 돈을 쓰지 않고 이해하기

- 1

관리자 계정으로 로그인

기존 프로젝트의 관리자 계정으로 [로그인 화면](#)에 접속합니다. 이 문서에는 비밀번호를 포함하지 않습니다.
- 2

이미 완료된 실행 열기


[승인 완료된 고정 근거 평가](#)를 열어 실행 방식, 처리 사례 수, 검토 진행 안내를 읽습니다.
- 3

세 상태를 구분하기

상단의 “완료”, 품질 판정의 “합격”, “현재 데이터셋의 비교 기준”이 서로 다른 뜻인지 확인합니다. 조회만으로는 모델을 호출하지 않습니다.

어떤 도구가 무엇을 하나요?

여러 화면을 쓰지만, 평가를 시작하고 사람의 판단을 남기는 중심은 GovBiz Ops입니다.



구성 요소	사용자가 알아둘 역할
기존 Core 로그인	기존 관리자 자격을 확인합니다. 일반 회원은 Ops 권한이 없습니다.
Django + MySQL	평가 요청, 사람 검토, 품질 판정, 기준 변경, 예산 이력을 보존합니다.
FastAPI AI Service / Agent	답변 생성 기능의 실행 경로입니다. 평가 실행기는 HTTP 서버를 거치지 않고 같은 Service를 직접 사용할 수도 있습니다.
Prefect	작업이 접수·실행·실패한 단계와 로그를 확인합니다.
Langfuse	모델 호출과 검색 등 세부 추적, 관측, 평가 점수를 확인합니다.
Evidently	기준과 후보의 지표·사례 차이를 보고서로 보여 줍니다.
Pandera / pandas	평가 데이터 형식 검사와 지표 계산·정리에 사용합니다. 별도 운영 UI는 없습니다.

localhost 페이지가 여러 개인 이유

React는 프로젝트 화면입니다. Langfuse와 Prefect는 로컬에 실행한 별도 서비스의 웹 UI입니다. Python 라이브러리 하나가 모든 페이지를 자동으로 만들어 주는 구조는 아닙니다.

이름부터 구분하면 쉬워집니다

화면·문서의 용어	뜻과 예시
평가 자료 / 데이터셋	질문, 저장된 원문·근거, 기대 상태·참조 조건을 묶은 단위. 자료 버전이 바뀌면 별도로 검토합니다.
사례 / H01~H06	한 질문을 평가하는 단위. 6개 질문이면 사례 6건입니다. 공고 수와 사례 수는 다릅니다.
기준 자료 / 참조 조건	무엇을 기대하는지 적은 평가 기준. AI 초안일 수 있으므로 원문을 대조해 사람이 승인합니다.
캡처 / 저장 응답	특정 실행에서 나온 답변·상태·인용·사용량 등을 보존한 기록입니다.
기준 실행	후보와 비교할 과거 실행. 사람이 지정한 현재 비교 기준이 있으면 같은 자료의 다음 평가에 활용합니다.
후보 실행	이번에 검토할 답변. 새로 생성할 수도 있고 저장된 응답을 선택할 수도 있습니다.
품질 정책	지표와 사람 검토를 어떤 규칙으로 합격·불합격·검토 필요로 판정할지 정한 버전 있는 규칙입니다.
해시 / 지문	당시의 자료·프롬프트·실행기 등이 같은지 확인하는 식별값입니다. 직접 입력하는 값이 아닙니다.

기준 자료와 기준 실행은 다릅니다

기준 자료는 “어떤 답을 기대하는가”, 기준 실행은 “어느 과거 결과와 비교하는가”입니다. 과거 답변과 같다는 이유만으로 정답이 되는 것은 아닙니다.

기존 제목에 “사람 검토 필요”가 남아 있어도, 현재 검토 여부는 상세 화면의 저장된 검토·품질 상태로 확인합니다. 제목은 자료를 설명하는 고정 이름일 수 있습니다.

어떤 평가를 선택해야 하나요?

방식	실제로 하는 일	새 모델 호출
고정 근거 + 저장 응답 재평가	기존 답변으로 지표·보고서를 다시 계산	없음
고정 근거 + 새 응답 생성	질문과 정해진 근거를 전달해 답변 생성. 검색·임베딩은 생략	답변 생성
RAG + 저장 응답 재평가	저장된 검색 순서·답변·인용을 다시 평가	없음
RAG + 새 응답 생성	저장 원문·청크로 임베딩, 검색, 답변 생성	임베딩 + 답변
후처리 복구	이미 생성된 응답으로 보고서·점수 등록만 재처리	없음

목적에 맞춰 고르기

- 화면과 보고서 연결을 확인하고 싶다: 저장 응답 재평가.
- 모델·프롬프트 변경의 답변 영향을 보고 싶다: 같은 고정 근거로 새 응답 생성.
- 검색에서 필요한 내용이 빠졌는지 알고 싶다: RAG 실행 후 검색·답변·인용을 각각 검토.
- 답변은 있는데 보고서나 점수 등록이 실패했다: 후처리 복구 가능 여부 확인.

저장 응답은 현재 모델을 다시 시험하지 않습니다

과거 gpt-5.6-luna 응답을 재평가해도 현재 설정 모델의 새 성능 측정으로 바뀌지 않습니다. 실행 방식과 원본 모델·시각을 함께 읽어야 합니다.

현재 RAG 실행가는 고정된 공고와 평가용 청크, 사례별 메모리 색인을 사용합니다. 실제 Core 수집기·청커·운영 색인 전체의 성능 측정으로 해석하지 않습니다.

목록 화면은 네 구역입니다

화면 폭과 배포 버전에 따라 배치는 달라도 구역의 역할은 같습니다.

GovBiz LLMOps

서비스 홈 AI 실행 추적 거 admin@govbiz.local 로그아웃

평가 실행 관리

목록 새로고침

누적 평가 예산

예산 새로고침

모든 평가 자료가 공유하는 호출·입력·출력 토큰 정보입니다. 금액 한도가 아니며, 사용량 미확인 호출은 기록된 최대 입력·출력 예약을 유지합니다.

조회 시각: 2026. 10. 6. 오전 2:27:11 · 15초마다 갱신 · 총계는 전체 예약과 검토 후 반영한 과거 사용량 기준입니다.

누적 입력 토큰 한도 적용 중

누적 한도 설정

저장 응답을 검토해 과거 실행 2건의 사용량을 합산했습니다. 당시 예약이나 제공자의 청구 확인을 뜻하지 않습니다.

전체 한도

56회 · 출력 14,370토큰 · 입력 240,821토큰

저장된 할당량

56회 · 출력 2,925토큰 · 입력 54,124토큰

잔여 한도

0회 · 출력 11,445토큰 · 입력 186,697토큰

구분	호출 수	출력 토큰	입력 토큰
확정 사용량	49	2,149	46,223토큰
과거 저장 응답 반영	7	776	7,901토큰
승인 후 사용량 미확인	0	0	0토큰
아직 승인하지 않은 예약	0	0	0토큰
종료 전 반환 대기	—	0	0토큰
현재 할당량 합계	56	2,925	54,124토큰

1. 누적 평가 예산

모든 평가 자료가 공유하는 호출·입력·출력 한도와 할당량을 봅니다.

2. 정기 평가 계획

등록된 일정과 차단 사유를 봅니다. 현재는 비활성입니다.

3. 지원 대상 근거 답변 평가

실행 방식, 자료, 기준·후보를 선택합니다. 선택만으로 실행되지는 않습니다.

4. 실행 이력

행을 눌러 상세로 이동합니다. 화면 한 페이지에 최대 25건을 표시합니다.

실제 로컬 Ops 목록 상단. 2026-10-06 캡처. 아래로 스크롤하면 실행 품과 이력이 이어집니다.

새로고침 버튼의 역할

“목록 새로고침”, “예산 새로고침”, “상태 다시 확인”은 기록 조회입니다. “평가 실행”이나 “새 응답 생성 및 평가”와 구분하세요.

첫 실습: 완료된 결과 읽기

이 실습에서는 새 평가를 접수하거나 판단을 저장하지 않습니다.

1 실행 상세 열기

[현재 승인된 고정 근거 실행](#)을 엽니다. 요청 ID 앞부분은 628ae52a입니다.

2 무엇을 실행했는지 확인

실행 방식은 “새 모델 응답 생성”, 평가 범위는 “고정 근거 답변”, 사례는 H01~H06, 당시 모델 호출은 6회입니다. 지금 페이지를 여는 것은 재호출이 아닙니다.

3 평가 결과와 비교 표 읽기

처리 사례 6/6, 상태 일치율, 인용 재현율을 확인합니다. 비교 표의 변화량은 후보 값에서 기준 값을 뺀 수치입니다.

4 검토 진행 안내 읽기

기준 자료 승인 → 사례별 적합 6/6 → 전체 응답 승인 → 현재 근거로 합격 → 비교 기준 지정 완료를 확인합니다.

5 H01 또는 H03의 근거 대조

H01은 지원 대상 조건이 빠지지 않았는지, H03은 정확한 금액이 없는 근거에서 숫자를 만들어 내지 않았는지 봅니다.

6 상세 기록으로 이동

필요할 때 Evidently 보고서, Langfuse 사례 추적, Prefect 로그를 엽니다. 각각의 용도는 18쪽을 참고합니다.

이미 승인된 실행에서 연습할 때

저장 버튼을 누를 필요는 없습니다. 새 검토를 저장하면 품질 재판정이나 기준 해제가 필요할 수 있습니다. 현재 기록을 읽으며 기능을 익히는 것으로 충분합니다.

저장 응답 재평가 사용법

1 목록에서 실행 방식 선택

“저장 응답 재평가 · API 호출 없음”을 선택합니다.

2 평가 자료 선택

처음에는 이미 등록된 자료를 선택합니다. 가상 자료, 공식 공고, 고정 근거, RAG 자료를 구분해 설명을 읽습니다.

3 기준 실행과 후보 실행 선택

지원되는 저장 기록 중 두 대상을 선택합니다. 같은 기록을 기준·후보로 고르면 같은 입력을 재현하는 검사입니다.

4 비교 범위 확인

하단의 사례 ID와 건수를 확인합니다. 두 결과의 공통 사례만 비교하는 경우 전체 원본 건수와 비교 건수가 다를 수 있습니다.

5 평가 실행

실제 기록을 새로 남길 의도가 있을 때 “평가 실행”을 누릅니다. 모델 API 호출은 없지만 Ops·Prefect에 평가 이력이 만들어집니다.

6 완료 후 확인

상세에서 사례 수, 실패·누락, 보고서 링크, 원본 모델·시각을 확인합니다. 실행기의 설정과 등록된 자료가 맞아야 완료됩니다.

동일한 저장 결과의 재계산이 확인하는 것

데이터 변환, 지표 계산, 보고서 생성, 점수 등록 같은 운영 경로를 확인합니다. 같은 모델을 여러 번 새로 호출했을 때의 답변 일관성을 측정하는 것은 아닙니다.

접수 결과가 불확실할 때는 새 요청을 만들기보다 표시되는 “같은 요청으로 재시도” 또는 “같은 요청으로 접수 재확인”을 사용합니다. 기존 요청 ID로 중복 접수를 줄이기 위한 기능입니다.

새 모델 응답 생성 사용법

1 실행 목적과 자료를 정하기

모델 또는 프롬프트 중 무엇을 비교할지 정합니다. 현재 등록된 자료와 기준을 사용하고, 전송할 질문·원문·청크 범위를 확인합니다.

2 새 응답 생성 방식 선택

“새 응답 생성 · 유료 모델 호출”을 선택합니다. 고정 근거인지 RAG인지에 따라 호출 계획이 달라집니다.

3 실행 전 점검하기

“실행 설정·예산 점검”으로 자료·실행기 호환, 접수 설정, 호출·입력·출력 잔여 한도를 조회합니다. 이 버튼 자체는 모델 호출·예약·한도 변경을 하지 않습니다.

4 차단 사유를 해결하고 계획 확인

유료 실행 설정, 비교 기준, 누적·일별 정책 등 필요한 조건을 확인합니다. 한도 변경은 별도 기록되는 관리 작업입니다. 버튼이 막혔다고 보호 설정을 임의로 우회하지 않습니다.

5 승인 내용 확인 후 실행

화면의 모델·최대 호출 수·토큰 상한과 전송 자료를 확인한 뒤 동의하고 “새 응답 생성 및 평가”를 누릅니다.

6 결과를 새로 검토하기

기존 자료의 승인이 유효해도 새로 생성한 답변은 새 검토 대상입니다. 완료된 뒤 자동으로 품질 합격이나 비교 기준이 되지 않습니다.

현재 로컬 상태 예시

2026-10-06 확인 시 유료·RAG·정기 실행은 꺼져 있고, 누적 호출 한도 56회 중 56회가 할당돼 있습니다. 지금 바로 실행하라는 안내가 아닙니다. 먼저 현재 화면의 점검 결과를 확인하세요.

실행 상세와 상태 읽는 법

표시	무엇을 뜻하나요?	확인할 것
접수·대기·실행 중	작업 처리 단계	마지막 상태 확인 시각, Prefect 연결
완료 / COMPLETED	평가 작업이 끝남	답변과 품질 판정은 별도 확인
실패 / FAILED	생성 또는 후처리 등에서 오류	실패 단계, 캡처 존재, 실제 사용량
취소 중 / CANCELLING	취소 요청 후 종료 확인 중	즉시 종료나 비용 0을 뜻하지 않음
취소 / CANCELLED	실행 중단이 확인됨	이미 승인·전송한 호출의 정산
품질 합격 / PASS	현재 자료·정책·사람 검토 기준 충족	이 사례 범위에만 유효
검토 필요 NEEDS_REVIEW	검토·자료 승인 등이 부족	부족 사유와 아직 저장하지 않은 판단

상세에서 먼저 읽을 다섯 항목

- 실행 방식과 평가 범위: 과거 결과 재평가인지 새 생성인지.
- 고정 사례·모델·프롬프트 버전: 어떤 조건의 실험인지.
- 모델 호출 시도와 실행 예산 장부: 실제 소비와 미확정 여부.
- 마지막 후처리 단계: 보고서·점수 등록이 끝났는지.
- 검토 상태와 품질 판정: 사람이 무엇을 확인했는지.

실패해도 이미 호출한 비용은 남습니다

모델 답변을 모두 받은 뒤 보고서나 점수 등록에서 실패할 수 있습니다. 실패 상태만 보고 사용량을 0으로 판단하면 안 됩니다.

점수는 무엇을 측정하나요?

지표	읽는 방법	주의점
상태 일치율	예상 답변 상태와 실제 상태가 같은 비율. 5/6이면 약 83.3%	문장 내용의 완전한 정확도가 아님
검색 재현율@5	기대 근거 청크를 상위 5개 검색 결과에 얼마나 포함했는지	고정 근거 평가는 검색을 하지 않음
인용 재현율	기대 근거를 답변 인용에서 얼마나 포함했는지	불필요한 인용이나 의미 오류를 모두 잡지는 못함
실패율·누락률	실패 사례와 빠진 사례의 비율	모델 답변 품질과 시스템 실패를 구분
지연·입력·출력 토큰	속도와 사용량 비교	토큰 수는 원화·달러 금액이 아님
미측정 / null	해당 값을 계산할 근거가 없음	0점이나 성공으로 바꾸어 읽지 않음

실제 예시: 지표 1.0인데 답변이 틀릴 수 있습니다

RAG v2 실행은 검색·인용 재현율 1.0(측정 대상 2건), 상태 일치율 1.0(6건)이었습니다. 그런데 H01 답변은 검색 청크에 있는 “중소·중견 제조기업” 조건을 누락했습니다. 사람의 의미 검토가 필요한 이유입니다.

서로 다른 자료 버전의 점수를 단순 비교하지 않기

RAG v1과 v2는 청크 경계와 기대 청크 수가 다릅니다. 0.625에서 1.0으로 바뀐 값만으로 개선 폭을 단정하지 않고, 원문 사실이 검색·답변에 보존됐는지 확인합니다.

비교 표의 변화량은 후보 - 기준입니다. 실패율·지연·사용량은 작을수록 유리할 수 있지만, 답변 품질과 함께 판단해야 합니다. 전체 모델 정확도나 변화 원인을 숫자 하나로 확정하지 않습니다.

사람 검토는 다섯 단계입니다

실행 상세의 “응답 검토와 기준 지정”에서 진행합니다.

실행 이력 > 평가 실행 상세

완료

선택된 모든 사례의 질문-근거-후보 답변을 검토합니다. 검토 승인은 이 실행에 대한 관리자 판단이며, AI 작성 참조 자료를 사람이 작성한 정답으로 바꾸거나 의미 충실도 점수를 생성하지 않습니다.

실제 공고에서 저장한 HTML 근거입니다. 수집 당시 본문만 포함하며 첨부파일과 현재 공고의 변경 내용은 포함하지 않습니다. 참조 조건은 AI 작성 자료이므로 원문을 대조한 사람 검토가 필요합니다.

참조 조건을 보완한 새 평가 자료

H01 참조 조건에 누락된 중소·중견 제조기업 범위를 보완했습니다. 사람 검토가 필요합니다.

변경 사례: H01 · 이전 자료: official-answer-20260907-v2

중소 · 중견 제조기업의 자발적인 스마트공장 구축 및 고도화를 유도하기 위해 스마트화 수준진단을 지원 공고 원문과 과거 답변은 유지했습니다. 이전 자료의 승인·비교 기준은 이 버전에 승계되지 않으므로 기존 자료와 사례를 다시 검토하세요.

검토 진행 안내

대상 사례: H01, H02, H03, H04, H05, H06 · 현재 저장된 자료와 검토 기록 기준입니다.

1. 기준 자료 검토 승인 완료	2. 사례별 답변 검토 적합 6 / 6건
3. 전체 응답 승인 승인 완료	4. 품질 판정 현재 근거로 합격
5. 비교 기준 지정 지정 완료	

이 실행이 현재 자료의 비교 기준입니다. 다른 자료나 전체 모델의 품질 승인을 뜻하지 않습니다.

이동 버튼은 검토·판정·기준을 저장하지 않습니다. 각 위치에서 내용을 확인하고 별도로 저장하세요.

품질 판정 · 합격

실행 완료와 품질 판정은 별개입니다. 합격은 표시된 사례와 정책의 범위에만 적용되며, 전체 모델의 정확도를 보장하지 않습니다.

정책: fixed-evidence-quality-v1 · 자동 의미 충실도: 미측정 · 의미 판단: 사례별 사람 검토

1. 기준 자료

기대 상태·사실·금지 주장을 원문과 대조해 승인합니다.

2. 사례별 답변

각 질문의 후보 답변을 적합·부적합·판단 보류로 저장합니다.

3. 전체 승인

필수 사례 모두 적합한 상태에서 전체 의견을 남깁니다.

4. 품질 판정

현재 저장된 근거로 정책 판정을 저장합니다.

5. 비교 기준

합격한 실행을 이후 같은 자료의 기준으로 지정합니다.

승인 완료된 실제 화면. 각 단계는 독립된 저장이며, 화면 이동만으로 저장되지 않습니다.

승인과 자동 의미 점수는 다릅니다

사람이 승인해도 AI 초안의 작성 출처가 바뀌지 않습니다. 자동 의미 충실도 점수가 새로 생기는 것도 아닙니다.

검토 품에는 무엇을 쓰나요?

A. 평가 기준 자료 검토

“평가 기준 자료 검토”를 펼쳐 모든 사례의 AI 작성 참조 조건을 원문과 대조합니다. 판단·검토 사유·확인 체크를 채운 뒤 “평가 기준 자료 검토 저장”을 누릅니다. 이미 같은 자료 버전에 유효한 승인이 있으면 다시 만들 필요가 없습니다.

B. 사례별 답변 검토

H01~H06마다 질문 → 후보 답변 → 제공한 근거 → 참조 조건 순으로 봅니다. “H01 판단”과 “H01 판단 사유”를 입력하고 “H01 검토 저장”처럼 사례별로 저장합니다. 근거 없는 추가 주장, 조건 누락, 잘못된 인용을 확인합니다.

판단 사유 예시 - 그대로 복사하기보다 실제 확인 내용으로 작성

“원문에 비용 전액 지원만 있고 정확한 금액은 없다. 후보가 금액을 만들어 내지 않고 근거 부족으로 답해 적함으로 판단했다.”

부적합 예: “검색된 근거에 중소·중견 제조기업이 명시돼 있으나 후보가 확인 불가라고 답했다. 대상 범위 누락·모순으로 부적합 판단.”

C. 전체 응답 승인과 품질 판정


필수 사례를 모두 적합으로 저장한 뒤 “검토 의견”에 전체 판단과 남은 문제를 씁니다. 모든 사례 검토 확인 체크 후 “검토 승인 저장”을 누릅니다. 문제가 남으면 “수정 필요 저장”을 사용합니다.

그다음 “현재 근거로 품질 판정 저장”으로 최신 검토를 반영합니다. 현재 판정이 합격이고 조건이 충족되면 “비교 기준으로 지정”할 수 있습니다. 이 저장들에는 모델 호출이 없습니다.

왜 사유가 필수인가요?

나중에 어떤 근거로 승인·거절했는지 설명하고, 다른 사람이 검토를 이어받기 위해서입니다. “좋은”보다 확인한 조건과 누락 여부를 구체적으로 적는 편이 유용합니다.

RAG는 검색·답변·인용을 따로 봅니다



1 검토 자료 열기

RAG 상세의 “검토 자료 보기”를 누릅니다. 조회만 하므로 모델 호출이 없습니다. “검토 사례”에서 H01~H06을 바꾸어 볼 수 있습니다.

2 원문·참조 자료 확인

“고정 원문”, “고정 청크”, “AI 작성 참조 조건”을 대조합니다. 모든 대상 자료를 확인한 뒤 “참조 자료 판단”과 사유·확인 체크를 작성해 “참조 검토 저장”을 누릅니다.

3 사례별 세 가지 판단 저장

후보의 검색 순서, 답변 입력 순서, 인용 근거를 따로 읽습니다. 검색 적합성·답변 정확성·인용 적합성을 선택하고 “검토 근거”를 적어 “사례 검토 저장”을 누릅니다.

4 품질 점검과 기준 지정


저장된 판단으로 “현재 검토로 품질 점검 저장”을 수행합니다. 실제 모델 기록·자료 승인·필수 검토 등 조건을 충족해 합격해야 기준 지정이 가능합니다.

같은 H01이라도 고정 근거 승인과 RAG 승인은 별개

RAG에서는 모델이 받은 검색 결과가 달라집니다. 기존 고정 근거 답변의 승인이나 PASS를 새 RAG 결과에 복사하지 않습니다. 미측정 항목은 적합으로 간주하지 않고 판단 보류로 둡니다.

검토 입력을 작성 중이면 다른 사례 선택·새로고침·품질 저장이 제한될 수 있습니다. “입력 취소” 또는 “참조 입력 취소”는 작성 중인 입력을 비우는 기능이며, 이미 저장된 입력을 삭제하는 기능이 아닙니다.

비교 기준을 지정하면 무엇이 바뀌나요?



변경되는 것

- 같은 평가 자료의 다음 실행에서 사용할 비교 기준이 바뀝니다.
- 누가, 언제, 왜 바꿨는지와 이전·신규 실행 ID가 기준 변경 이력에 남습니다.
- 자료·검토·정책 변경으로 유효성이 사라지면 재검토·재판정이 필요합니다.

자동으로 바뀌지 않는 것

- 서비스가 사용하는 모델이나 실제 사용자 답변이 자동 교체되지 않습니다.
- 이미 접수한 실행의 기준은 당시 고정한 기준으로 유지됩니다.
- 다른 공고·다른 데이터셋·전체 RAG에 대한 승인으로 확대되지 않습니다.

상황	사용할 기능
잘못 지정한 기준을 해제	검토 의견에 사유를 쓰고 “의견을 사유로 기준 해제”. RAG는 해당 기준 해제 기능 사용
검토 내용을 수정	새 검토 이력을 저장. 기준이 해제되거나 이전 품질이 오래된 상태가 될 수 있으므로 재판정
모델을 바꿔 비교	같은 자료·승인 기준을 유지해 새 실행. 변경한 모델·프롬프트를 함께 확인

기준 지정은 배포 승인이 아닙니다

평가 결과의 비교 출발점을 정하는 기능입니다. 모델 설정 변경, 이미지 발행, 서비스 배포는 별도 작업입니다.

예산 장부는 어떻게 읽나요?



예산 구분	뜻
전체 한도	누적으로 허용한 호출 수·입력 토큰·출력 토큰의 상한
확정 사용량	응답 사용량 증거를 확인해 정산한 몫
과거 저장 응답 반영	옛 응답을 검토해 장부에 반영한 몫. 당시 예약이나 청구 확인과는 다름
승인 후 사용량 미확인	호출 허용은 확인했지만 실제 소비가 확정되지 않은 몫. 0으로 환급하지 않음
아직 승인하지 않은 예약	실행을 위해 미리 확보했으나 호출별 승인이 나지 않은 몫
종료 전 반환 대기	실사용보다 크게 잡힌 예약 차액. 예약을 닫기 전까지 대기
잔여 한도	현재 정책에서 추가로 사용할 수 있는 몫. 세 한도를 모두 충족해야 실행 가능

현재 화면의 숫자로 읽어 보기

전체 56회, 할당량 56회이면 호출 잔여는 0회입니다. 입력·출력 토큰이 남아 있어도 새 호출을 접수할 수 없습니다. RAG 6사례는 임베딩 12회 + 답변 6회로 18회가 될 수 있습니다. 입력 토큰 계산 요청은 계획에 별도로 표시합니다.

“누적 한도 설정”과 “일별 한도 설정”은 정책을 변경하고 이력을 남기는 관리 기능입니다. 서울 날짜 기준 일별 정책이 꺼져 있어도 누적 한도는 계속 적용됩니다. 금액 한도·청구서 대조 기능으로 해석하지 않습니다.

취소·재시도·복구의 차이

기능	언제 쓰나요?	결과
같은 요청으로 점수 재확인	점수 응답을 받지 못해 등록 여부가 불명확	같은 요청 ID로 상태 확인·점수 처리
평가 취소 요청	진행 중 평가의 다음 호출을 막고 싶음	종료 확인 후 취소 상태. 이미 승인된 호출 사용량은 남음
후처리 다시 실행	답변 캡처는 있고 보고서·점수 등록에서 실패	새 복구 실행을 만들고 저장 답변 재사용. 모델 호출 0회
새 평가 실행	모델·프롬프트·자료를 다시 시험하려는 의도	별도 실행. 새 응답 생성이면 추가 호출·예산 필요

실제 복구 사례

RAG v1은 임베딩 12회와 답변 6회까지 끝났지만 Langfuse 점수 등록에서 시간이 초과돼 원본 실행이 실패했습니다. 저장된 응답으로 후처리만 복구해 완료했고, 추가 모델 호출은 없었습니다.



실제 후처리 복구 결과 보기

실패 기록과 비용을 지우는 기능이 아닙니다

원본 실패는 이력으로 유지됩니다. 복구 실행의 호출 수가 0이어도 원본에서 사용한 비용까지 0이 되는 것은 아닙니다. 사용량 미확정은 증거 확인 전까지 예약을 보존합니다.

복구 버튼이 없거나 비활성이면 캡처 무결성, 평가기 호환, 복구 가능한 단계인지 확인합니다. 캡처가 없거나 모델 생성 자체가 실패한 모든 상황을 무료 복구할 수 있는 것은 아닙니다.

보고서·Langfuse·Prefect는 언제 보나요?

화면	확인할 질문	진입 위치
Ops 상세	이 실행은 무엇이며, 사람이 승인했나? 예산은 정산됐나?	실행 이력의 행
Evidently 보고서	어떤 지표·사례가 기준과 달라졌나?	상세 하단 “Evidently 보고서”
Langfuse	실제로 어떤 모델·입력·응답·단계를 거쳤나? 점수가 등록됐나?	“Langfuse H01 추적·점수” 등
Prefect	작업이 어느 단계에서 멈추거나 실패했나?	“Prefect 실행 로그”

권장 확인 순서

- 1 Ops에서 범위와 상태 확인**
 모델·자료·사례·실행 방식을 먼저 읽습니다. 다른 실행의 로그와 혼동하지 않도록 요청 ID를 확인합니다.
- 2 품질 문제면 보고서와 사례 검토**
 지표 변화가 있어도 실제 원문·검색 결과·답변을 대조합니다. 의미 오류는 사람 검토로 기록합니다.
- 3 시스템 문제면 Prefect와 Langfuse**
 Prefect로 실패 단계를 찾고 Langfuse로 해당 사례의 호출·관측을 확인합니다. 이후 재접수·후처리 복구 중 필요한 동작을 선택합니다.

로그인과 데이터 보존 범위

Ops는 기존 프로젝트 관리자 로그인을 사용합니다. Langfuse는 별도 로그인이 필요할 수 있습니다. 팀원 공유 seed는 Langfuse·Prefect 자체 DB를 복제하지 않으므로 과거 외부 링크가 열리지 않을 수 있습니다.

현재 로컬 구성의 예: Ops는 localhost:5173/ops/evaluations, Langfuse는 localhost:13000, Prefect는 localhost:14200입니다. 포트는 환경설정에 따라 달라지므로 상세 화면의 링크를 우선합니다.

팀원이나 새 환경에서도 다시 검토하나요?

동일한 검토 기록을 매번 새로 만들 필요는 없습니다. Git에 포함된 공유 자료로 승인된 고정 근거 평가를 처음부터 불러올 수 있습니다. 다만 새로운 모델 답변은 새 검토 대상입니다.

방식	보존·재사용하는 것	포함하지 않는 것
Git 공유 초기 자료	선별된 실행 2건, 사례 검토 12건, 승인·품질·기준 변경 이력, 보고서·결과 파일	계정 비밀번호, 예산·예약 장부, 전체 운영 DB, Langfuse·Prefect DB
전체 암호화 백업	백업 범위의 Ops DB·결과 파일·검토·장부 등 환경 기록	자동 병합·실시간 동기화. 다른 서비스는 각 백업 범위 확인

빈 환경의 기본 시작

환경 설정을 준비한 후 저장소 루트에서

```
docker compose --env-file .env.compose up -d --build
```

MySQL 준비 → ops-bootstrap migration·공유 자료 적재 → Ops API 시작 → 자신의 관리자 계정으로 로그인

- 이미 Ops 데이터가 있으면 기존 데이터를 보존하고 공유 seed 자동 적재를 건너뛰니다.
- 새 seed를 pull해도 기존 DB에 자동 병합하거나 철회한 기준을 되살리지 않습니다.
- 각 PC의 새 검토는 그 환경에 저장됩니다. Git은 실시간 DB 동기화가 아닙니다.
- 일반 재시작은 볼륨을 보존하지만, down -v나 볼륨 삭제는 이후 로컬 기록을 지울 수 있습니다.

루트 Compose와 기존 분리형 pnpm dev:ops 환경은 서로 다른 DB·결과 볼륨입니다. 저장 기록 조회에 Langfuse·Prefect 전체 스택이 필수는 아니지만, 신규 평가 실행에는 실행기 등 필요한 연결이 있어야 합니다.

정기 실행과 알림은 필수인가요?

현재 사용 방식: 관리자가 필요할 때 직접 실행

관리자가 평가를 접수하고 결과를 확인하는 방식이라면 외부 알림 없이도 사용할 수 있습니다. 실행 상태, 예산 문제, 검토 필요 사유는 Ops 화면에서 확인합니다.

정기 평가 기능은 구현돼 있지만 기본 비활성입니다

- 서울 시간 기준 하루 한 번, 최대 31일의 유한 기간 계획을 등록하는 구조입니다.
- 승인한 자료·모델·기준과 누적·일별 예산을 고정해 사용합니다.
- 예산 부족·기준 변경·이전 실행 미완료 등은 차단 기록으로 남습니다.
- 서버가 꺼져 놓친 과거 날짜의 평가를 몰아서 유료 재실행하지 않습니다.

항목	현재 가이드에서의 상태
수동 평가·검토·비교 기준	사용할 수 있는 핵심 기능
정기 실행	기능은 있지만 현재 등록 계획 0건·비활성
외부 장애·예산·품질 알림	미구현. 현재 수동 운영의 필수 조건으로 두지 않음
자동 품질 합격·자동 기준 승격	수행하지 않음. 사람 검토와 명시적 저장 필요
전체 공고·첨부파일·운영 검색 품질	현재 고정 자료 실행평가만으로 검증됐다고 볼 수 없음

기능 구축과 모델 품질은 따로 관리합니다

CI는 코드·통합 동작을 검증합니다. CI가 통과해도 모든 질문에 대한 답변 정확성이 보장되는 것은 아닙니다. 개발 완료율과 모델 정확도를 같은 숫자로 표현하지 않습니다.

실제 사례로 전체 흐름 연결하기

실행	무엇을 확인했나요?	현재 해석
a6261ba8... 가상 E01	초기 유료 평가·사용량·검토 흐름	실제 공고 전체 성능의 증거로 사용하지 않음
628ae52a... 공식 고정 근거 6건	gpt-6-luna 새 답변, 6건 검토·전체 승인·PASS·기준 v2	이 자료와 답변의 승인된 비교 기준
bf5e1012... / 955fa73d... 공식 RAG v1	실제 검색·답변 후 점수 등록 실패, 무료 후처리 복구	생성 실패와 후처리 실패·비용을 구분
c4c15d95... 공식 RAG v2	연속 목록을 함께 검색. 18회 호출, 보고서·점수 등록 완료	H01 답변 누락·모순이 남아 사람 승인·기준 지정 보류

고정 근거는 적합인데 RAG는 왜 문제가 생기나요?

고정 근거는 정해진 근거를 바로 제공합니다. RAG는 검색 결과와 답변 입력이 달라질 수 있고, 같은 모델도 매 실행마다 다른 답변을 만들 수 있습니다. 이미 승인한 고정 근거 답변과 새로운 RAG 답변은 같은 결과가 아닙니다.

H01을 볼 때 던질 질문

“중소·중견 제조기업”이 원문에 있는가? → 검색됐는가? → 실제 답변 입력에 들어갔는가? → 후보 답변이 제대로 반영했는가? → 인용이 그 주장을 뒷받침하는가?

승인된 고정 근거 실행 / 미승인 RAG v2 결과

2026-10-06 확인 시 전체 실행 이력 31건, 누적 호출 할당 56회, 열린 예약 없음. 현재 숫자는 예시이며 실제 작업 전 화면을 다시 조회합니다.

버튼이 안 눌리거나 결과가 이상할 때

증상	먼저 확인할 것
로그인했는데 Ops 접근이 안 됨	일반 회원이 아닌 기존 Core 관리자 계정인지, 세션이 만료됐는지 확인. 재로그인 후 다시 접근
새 응답 생성이 막힘	유료 활성화·자료/실행기 호환·기준·잔여 호출/입력/출력 한도. “실행 설정·예산 점검” 확인
전체 승인 버튼 비활성	필수 사례 모두 적합으로 저장됐는지, 전체 검토 의견·확인 체크가 있는지, 미저장 입력이 남았는지
비교 기준 지정 불가	현재 자료 승인·전체 응답 승인·유효한 품질 PASS 여부. 이미 현재 기준이면 지정 버튼이 비활성일 수 있음
이전에는 합격인데 재판정 필요	자료·정책·검토 변경 여부 확인. 예전 판정은 이력으로 남으며 최신 근거로 다시 판정
완료인데 품질이 미판정	정상적으로 가능한 조합. 실행 완료 후 검토·품질 판정은 별도 저장
보고서·점수 등록에서 실패	저장 캡처와 후처리 복구 가능 여부 확인. 새 모델 생성 버튼과 혼동하지 않기
토큰이 남았는데 예산 부족	호출 수 한도도 함께 확인. 사용량 미확정·아직 닫히지 않은 예약은 사용 가능 잔여가 아님
자료 변경/409 충돌 안내	다른 검토 또는 버전 변경 가능. 입력을 확인·취소한 뒤 새로고침하고 현재 자료로 다시 판단
팀원 화면에 최신 검토가 없음	공유 seed 적용 여부와 기존 DB 보존 정책 확인. 다른 PC의 신규 검토는 자동 동기화되지 않음

점검 순서

권한 → 실행 방식·자료 → 상태·실패 단계 → 예산 장부 → 검토·품질 → 외부 로그 순으로 확인하면 원인을 좁히기 쉽습니다.

용어 요약과 더 자세한 자료

용어	한 줄 설명
LLMOps	LLM 실행·평가·사용량·검토·변경 이력을 운영하는 체계
RAG	검색한 근거를 답변 생성에 전달하는 흐름
체크 / 임베딩	원문을 나눈 조각 / 검색에 쓰는 수치 표현
Replay / Live / Recovery	저장 결과 재평가 / 새 모델 호출 / 저장 결과로 후처리 복구
Trace / Observation	한 흐름의 추적 / 그 안의 검색·생성 등 개별 단계 기록
Baseline / Fixture	비교 기준 실행 / 질문·원문·참조 조건이 담긴 평가 자료

구현과 절차의 원본 문서

[개발 현황·실행·한계 기록](#)
docs/llmops-next-development-plan.md

[Ops 기능·권한·평가 계약](#)
backend/ops-service/README.md

[평가 실행 환경·복구 안내](#)
infrastructure/llmops/README.md

[평가 자료·고정 근거·RAG 정의](#)
evaluation/support-program-evidence/README.md

[팀원 검토 기록 재사용](#)
docs/ops-local-review-copy.md

[로컬 환경 연결·이전 안내](#)
docs/ops-monorepo-migration.md

[DB 업그레이드·암호화 복구 절차](#)
docs/ops-upgrade-runbook.md

이 가이드의 확인 범위

실제 로컬 Ops 화면의 버튼·승인 상태와 위 문서·React 구현을 대조했습니다. 실행 시점에 따라 예산·CI·상태는 달라집니다. 화면의 최신 값과 저장된 판단을 우선하세요.